

Python程式設計 期末報告



主題：網路爬蟲

台灣大學 經濟三 楊智宇

主要功能：

1. 可自行輸入欲爬蟲的ptt網址，及欲抓取的頁數。
2. 印出抓取的結果，並將輸出格式化。
3. 可選擇是否要匯出成csv檔。

<https://goo.gl/ivMCMQ>

程式碼

project01.py x

```
1 import requests
2 from bs4 import BeautifulSoup
3 from pretty_print import pretty_print ## 美化輸出
4 import urllib.parse ## url 相關應用
5
6 index = str(input('想抓取哪個ptt看板? (ex: Movie版請輸入 https://www.ptt.cc/bbs/movie/index.html) : \n'))
7 pages = eval(input('想抓取幾頁呢? ex: 5 : '))
8
9 not_exist = BeautifulSoup('<a>(本文已被刪除)</a>', 'lxml').a ## '本文已被刪除'的結構不同，自行生成<a>
10
11 def get_articles_on_ptt(url):
12     response = requests.get(url)
13     soup = BeautifulSoup(response.text, 'lxml') ## 網頁原始碼
14     articles = []
15
16     for i in soup.find_all('div', 'r-ent'):
17         meta = i.find('div', 'title').find('a') or not_exist ## 當爬到是空的，讓 meta = 0
18         articles.append({
19             'title': meta.getText().strip(), ## strip 去除頭尾字符，預設是空白
20             'push': i.find('div', 'nrec').getText(),
21             'date': i.find('div', 'date').getText(),
22             'author': i.find('div', 'author').getText(),
23         })
24
25     next_link = soup.find('div', 'btn-group-paging').find_all('a', 'btn')[1].get('href') ## 控制頁面選項(上一頁)
26
27     return articles, next_link
28
29 def get_pages(num): ## 要爬幾頁
30     page_url = index
31     all_articles = []
```

project01.py x

```
29 def get_pages(num): ## 要爬幾頁
30     page_url = index
31     all_articles = []
32
33     for j in range(num):
34         articles, next_link = get_articles_on_ptt(page_url)
35         all_articles += articles
36         page_url = urllib.parse.urljoin(index, next_link) ## 將上一頁按鈕的網址和 index 網址比對後取代
37
38     return all_articles
39
40 data = get_pages(pages)
41
42 for k in data:
43     pretty_print(k['push'], k['title'], k['date'], k['author'])
44
45 csv_or_not = input('輸入 y 以匯出成csv檔，輸入其他結束程式：')
46
47 if csv_or_not == 'y':
48     board = index.split('/')[2]
49     csv = open('./ptt_%s版_前%d頁.csv'%(board, pages), 'a+', encoding='utf-8')
50     csv.write('推文數,標題,發文日期,作者ID,\n')
51     for l in data:
52         l['title'] = l['title'].replace(',', '，') ## 與用來分隔的逗點作區別
53         csv.write(l['push'] + ',' + l['title'] + ',' + l['date'] + ',' + l['author'] + ',\n')
54     csv.close()
55     print('csv檔案已儲存在您的資料夾中。')
56 else:
57     quit()
```

執行過程

project01.py x

```
1 import requests
2 from bs4 import BeautifulSoup
```

問題 輸出 偵錯主控台 終端機

2: Python

Microsoft Windows [版本 10.0.16299.192]

(c) 2017 Microsoft Corporation. 著作權所有，並保留一切權利。

```
C:\Users\Christopher Yang\Desktop\Python\py>python "c:\Users\Christopher Yang\Desktop\Python\py\project_final\project01.py"
想抓取哪個ptt看板？(ex: Movie版請輸入 https://www.ptt.cc/bbs/movie/index.html) :
```


project01.py x

```
1 import requests
2 from bs4 import BeautifulSoup
```

問題 輸出 偵錯主控台 終端機

2: Python

Microsoft Windows [版本 10.0.16299.192]

(c) 2017 Microsoft Corporation. 著作權所有，並保留一切權利。

C:\Users\Christopher Yang\Desktop\Python\py>python "c:\Users\Christopher Yang\Desktop\Python\py\project_final\project01.py"

想抓取哪個ptt看板？(ex: Movie版請輸入 https://www.ptt.cc/bbs/movie/index.html)：

https://www.ptt.cc/bbs/movie/index.html

想抓取幾頁呢？ex: 5: █

project01.py x

```
1 import requests
2 from bs4 import BeautifulSoup
```

問題 輸出 偵錯主控台 終端機

2: Python

2	[討論] 《金錢世界》事件那幾年,小孩有被警告嗎?	2/09 Emerson158
1	[好雷] 決勝女王-守護自己真正在意的事	2/09 ad56
1	[普好雷] 巴黎列車- 褒貶一線間	2/09 vctlick
3	[選片] 巴黎列車 金錢世界	2/09 iamanidiot
20	[新聞] 超壯觀!「漫威宇宙十周年」超級英雄大合	2/09 Carter8123
	[好雷] 歡迎光臨奇幻城堡	2/09 ANDYisME
1	[問片] 求片名 未來人類回到過去 製造災難	2/09 corainn
5	[公告] 《各式疑難雜症FAQ》	2/04 VOT1077
爆	[公告] 板規! 必看! 好文推薦·惡文檢舉	7/30 VOT1077
爆	[討論] 各位2017看過的電影,the Best會給哪部呢?	12/14 Emerson158
爆	[情報] 2018 奧斯卡金像獎 入圍名單	1/23 qpr322
54	[情報] 2018年 第90屆奧斯卡 入圍影片 台灣映期	1/23 filmwalker
29	[討論] 《羊男》如果是英語片,當年會得奧斯卡	2/08 tontontonni
8	Re: [討論] 環太平洋2 中國神翻譯預告	2/08 shirman
	[討論] 靈魂交換新片	2/08 nancy3nancy3
16	[問片] 一部古埃及詛咒的老恐怖片神鬼艷后/天煞	2/08 Naal
9	Re: [贈票] 《BPM》台北特映會搶先看	2/08 xup6m3rmp
2	(本文已被刪除)	2/08 -
	Re: [討論] 環太平洋2 中國神翻譯預告	2/08 cloud72426
1	[討論] 縮小人生一幕	2/08 kc092444
11	[討論] 像"艾蜜莉布朗"一樣又正又魯的女星?	2/08 peter080808
49	[新聞] 《猛毒》前導預告釋出	2/08 rz759
3	[問片] 小女孩是惡鬼/惡魔?	2/08 suumire
1	[普好雷] 《誰是大壞狐》	2/08 janice100
3	[極好雷] 縮小人生: 存在主義治療	2/08 gushing
X1	(本文已被刪除)	2/08 -
7	[討論] 霓裳魅影的Cyril	2/08 dragon50119
11	[情報] 艾米漢默將主演《闇影之下》導演編導未命名新片	2/08 qpr322
1	[問片] 一個人被卡在工地電梯上	2/08 ting19841207
3	Re: [贈票] 票選2017的年度電影片單(贈票公布&候補)	2/08 popchieh
2	[普雷] 格雷的五十道陰影-自由	2/09 babe18

project01.py x

```
1 import requests
2 from bs4 import BeautifulSoup
```

問題 輸出 偵錯主控台 終端機

2: Python

```
3  [問片] 『港片』全家參加省錢比賽          2/08 xinghh
   [新聞] 《格雷3》巴黎首映 「總裁夫人」美穿PRAD 2/08 huanglove
24 [新聞] 詹姆斯法蘭柯 衝浪避鋒頭揪爽        2/08 huanglove
8  [請益] 雷-霓裳魅影 衣服的内襯            2/08 filmmaker
31 [新聞] 63歲男星蜜戀31歲小模 拖了2年終於要離 2/08 huanglove
6  (本文已被刪除)                            2/08 -
5  [好雷] 誠意滿點之角頭2                    2/08 akbobo
42 [新聞] 《逃出絕命鎮》拍續集? 導演:有很多故 2/08 sosoing
4  Re: [情報] 第37屆香港電影金像獎提名名單    2/08 tools
2  [好雷] 王牌業務員Es war einmal in Deutschland 2/08 mysmalllamb
2  [新聞] 韓國女導演李賢珠被曝性侵女同事      2/07 hahaha0204
   [負雷] 決勝女王 覺得編劇不專業            2/07 inbow
3  [討論] 池畔謎情看完的疑惑                  2/07 s2657507
38 [選片] 花甲大人轉男孩 格雷的五十道陰影    2/07 babe18
   Re: [新聞] NETFLIX以超過五千萬美元取得《科洛弗悖論 2/07 femlro
50 [討論] 「死侍2」最新預告                    2/07 beckseaton
   (本文已被刪除)                            2/07 -
22 [好雷] 水底情深 - 我的小怪物你在哪?        2/07 priliona
   [贈票] 《獄火重生:金昌洙》台北台中特映會    2/07 g3yu
3  [好雷] 《霓裳魅影》 - 不自知的虐戀渴望      2/07 leila
10 [普雷] 《科洛弗悖論》-行銷手法的驚喜大過電影 2/07 leila
11 (本文已被刪除)                            2/07 -
2  [新聞] 「小美」、「十四顆蘋果」 出征柏林影展 2/07 iam168888888
爆 Re: [新聞] 【不可能的任務:全面瓦解】最新預告 2/07 draft
6  [好無雷] 角頭2 國產黑幫片誠意之作          2/07 tieamonk
2  [片單] 類似金牌黑幫的電影                  2/07 HOWARDNO1
24 [請益] 第一次看格雷可以懂劇情嗎?          2/07 syensyens
1  [新聞] 特派專欄:寶萊塢電影引發暴動背後的真相 2/08 sarada
17 [討論] 金馬獎的口味是不是很難捉摸?        2/08 takuminauki
2  Re: [討論] <氣象戰>裡的一個疑問            2/08 imrt
```

輸入 y 以匯出成csv檔, 輸入其他結束程式:

ptt_movie版_前5頁

X1

[請益]

請問有人不用蘋果手機,微軟辦公,谷歌搜尋

2/08 candybeer

Thank You